

Evaluación Experimental y Análisis Crítico de una Estructura Aumentada para Reportes RAP

Autor: Maykoll Vanegas Silva | Docente: Ana Tapia, Ph.D. | Materia: Análisis de Algoritmos

Resumen— Este informe presenta la evaluación experimental de una estructura de datos aumentada diseñada para almacenar y consultar informes de retroalimentación automática de presentaciones orales del sistema RAP (Ochoa et al., 2018). Frente a esquemas tradicionales basados en barridos secuenciales $O(N)$, se implementó una arquitectura desacoplada en dos etapas: (i) índices secundarios en memoria mediante cuatro árboles AVL aumentados con invariantes (C , S , SS) que resuelven consultas estadísticas por intervalo en tiempo logarítmico $\Theta(\log D_m)$, y (ii) almacenamiento primario persistente en un motor LSM-Tree (LevelDB 1.23) optimizado con filtros probabilísticos (Bloom y Ribbon). Las pruebas sobre 1,000, 10,000 y 50,000 reportes demuestran factores de aceleración de hasta **9,300x** en agregaciones de rango y una reducción del 18.2% en latencia de recuperación, analizando de forma crítica las fortalezas asintóticas y las debilidades operativas asociadas a la gestión de memoria y el dimensionamiento de servidores.

1. Introducción y Contexto Operativo de RAP

El sistema RAP (*Automatic Presentation Feedback*, Ochoa et al., 2018) provee retroalimentación sobre habilidades de exposición oral mediante sensores multimodales de bajo costo. Cada presentación genera un informe que resume métricas cuantitativas de contacto visual, volumen y postura. En su concepción original, RAP almacena reportes como archivos independientes o registros relacionales sin indexación secundaria multidimensional. Al acumular miles de presentaciones a lo largo de diversos periodos académicos, responder consultas agregadas de cohorte o clasificaciones mediante barridos lineales (**Fuerza Bruta**) impone una complejidad $O(N)$ que compromete la respuesta en tiempo real.

2. Modelo de Informes y Arquitectura Algorítmica

Cada informe se modela formalmente como $r_i = (id_i, u_i, t_i, M_i, D_i)$, donde id_i es el identificador único, u_i el expositor, t_i la marca de tiempo, D_i el payload JSON (~1 KB con desglose multimodal detallado) y $M_i = (g, z, v, p)$ reúne cuatro métricas continuas: puntaje global $g \in [1.0, 5.0]$, contacto visual $z \in [0.0, 1.0]$, volumen $v \in [0.0, 1.0]$ y postura $p \in [0.0, 1.0]$. Se implementó una **arquitectura desacoplada en dos fases**:

• **Fase 1 (Índices Secundarios Aumentados en RAM)**: Cuatro árboles AVL independientes (I_g, I_z, I_v, I_p). Cada nodo almacena la clave métrica k_x , una lista de identificadores L_x y campos aumentados de subárbol: cardinalidad $C(x) = C(x_L) + |L_x| + C(x_R)$, suma $S(x) = S(x_L) + k_x |L_x| + S(x_R)$ y suma de cuadrados $SS(x) = SS(x_L) + k_x^2 |L_x| + SS(x_R)$, actualizados en $\Theta(1)$ durante cada inserción y rotación. Mediante la función de prefijo AgregadoLE(t), las estadísticas de cualquier intervalo $[a, b]$ se calculan como $A_{[a,b]} = A_{\leq b} - A_{< a}$ en tiempo estricto $\Theta(\log D_m)$, independiente del número de elementos contenidos en el rango.

• **Fase 2 (Almacenamiento Persistente en LSM-Tree)**: Los payloads D_i residen en LevelDB 1.23. Tras resolver los predicados en RAM y determinar el conjunto de identificadores R_Q mediante intersección ordenada por cardinalidad creciente, se ejecutan lecturas puntuales MultiGet(R_Q) asistidas por filtros probabilísticos (**Bloom y Ribbon**).

3. Metodología Experimental y Validación de Correctitud

Los experimentos se ejecutaron sobre Linux 6.8 (Intel Core i5-12600KF, 32 GB RAM, NVMe) evaluando tres escalas: **$N = 1,000$** , **$N = 10,000$** y **$N = 50,000$** informes sintéticos generados siguiendo las distribuciones de RAP (semilla fija seed=42). Cada consulta se ejecutó 50 veces consecutivas para promediar latencias con resolución de nanosegundos.

Validación de Correctitud: Mediante pruebas unitarias automáticas (test_correctness.cpp) se verificó que el balance $|h_L - h_R| \leq 1$ se preserva rigurosamente (altura máxima $h = 11$ con 401 claves discretas), y que la media, varianza y desviación estándar calculadas en $\Theta(\log D_m)$ coinciden con exactitud matemática frente a Fuerza Bruta (error $\Delta < 10^{-6}$).

4. Resultados Experimentales Consolidados

A continuación se sintetizan las métricas de rendimiento obtenidas en las tres escalas evaluadas.

Tabla 1: Tiempo de Ingesta e Indexación en Memoria

Escala N	Ingesta Fuerza Bruta (std::vector)	Ingesta + 4 AVL Aumentados	Latencia por Informe
N = 1,000	0.354 ms	0.282 ms	0.282 μ s / informe
N = 10,000	3.277 ms	2.590 ms	0.259 μ s / informe
N = 50,000	15.585 ms	11.351 ms	0.227 μ s / informe

Tabla 2: Consultas Estadísticas de Rango (Algoritmo 4: AgregadoLE)

Escala N	Intervalo Evaluado	k Items	AVL Aumentado $\Theta(\log D)$	Fuerza Bruta $O(N)$	Factor Speedup
N = 1,000	Puntaje Global [3.50, 3.80]	358	0.0253 μ s (25 ns)	3.55 μ s	140.3x
N = 10,000	Puntaje Global [3.50, 3.80]	3,570	0.0299 μ s (30 ns)	39.84 μ s	1,331.7x
N = 50,000	Puntaje Global [3.50, 3.80]	17,896	0.0273 μ s (27 ns)	253.54 μ s	9,300.9x
N = 50,000	Mirada Audiencia [0.60, 0.85]	28,074	0.0391 μ s (39 ns)	220.13 μ s	5,629.8x
N = 50,000	Volumen de Voz [0.65, 0.90]	31,590	0.0334 μ s (33 ns)	182.15 μ s	5,453.6x

Tabla 3: Selección Top-k de Expositores (Algoritmo 7: TopK)

Escala N	Consulta	AVL Top-k $O(\log D + k)$	Fuerza Bruta $O(N \log k)$	Factor Speedup
N = 1,000	Top-10 Mejores Expositores	0.133 μ s	6.09 μ s	45.8x
N = 10,000	Top-10 Mejores Expositores	0.130 μ s	57.60 μ s	441.5x
N = 10,000	Top-50 Mejores Expositores	0.411 μ s	64.43 μ s	156.8x
N = 50,000	Top-10 Mejores Expositores	0.167 μ s	313.77 μ s	1,884.1x
N = 50,000	Top-100 Mejores Expositores	0.623 μ s	355.14 μ s	570.0x

Tabla 4: Materialización en Almacenamiento Persistente (LevelDB 1.23 + Filtros AMQ)

Escala N	Claves RQ	Sin Filtro (Baseline)	Bloom Filter (10 bpk)	Ribbon Filter (10 bpk equiv)	Ahorro AMQ
N = 1,000	215 items	3.298 μ s / op	2.712 μ s / op	2.698 μ s / op	18.2% ahorro
N = 10,000	2,146 items	3.271 μ s / op	2.687 μ s / op	2.675 μ s / op	18.2% ahorro
N = 50,000	10,801 items	2.282 μ s / op	2.292 μ s / op	2.324 μ s / op	Caché caliente
Misses (1k)	1,000 claves	0.057 μ s / op	0.066 μ s / op	0.049 μ s / op	Descarte veloz

5. Análisis Crítico: Fortalezas de la Propuesta

- 1. Invarianza Temporal Asintótica:** La mayor fortaleza es la estabilidad de AgregadoLE en $\Theta(\log D_m)$. El tiempo de respuesta se mantiene prácticamente constante (~25 a 30 nanosegundos) tanto para $N = 1,000$ como para $N = 50,000$, incluso cuando el intervalo engloba más de 17,800 informes. Al eliminar la dependencia de la cantidad de elementos seleccionados (k), la aceleración sobre Fuerza Bruta supera **9,300x**.
- 2. Desacoplamiento y Poda Selectiva de E/S (2,146 / 10,000):** En una consulta por notas en [4.00, 4.50] sobre 10,000 reportes, el índice en RAM determina que solo 2,146 cumplen la condición. El almacenamiento secundario ejecuta MultiGet únicamente sobre ellos, **evitando 7,854 lecturas a disco**. La E/S es estrictamente proporcional a la selectividad de salida.
- 3. Aceleración con Filtros AMQ Modernos (Ribbon vs. Bloom):** En LevelDB, los filtros probabilísticos reducen un **18.2%** la latencia de lectura puntual frente a la ejecución sin filtros. **Ribbon Filter** alcanza la misma velocidad que Bloom (2.675 μ s vs 2.687 μ s) pero con un 30% menos sobrecosto espacial teórico (~7.0 vs 10.0 bits/clave), optimizando la compresión de SSTables.
- 4. Poda Temprana en Consultas Compuestas:** Ordenar los predicados por cardinalidad creciente minimiza el tamaño de los conjuntos intermedios desde el primer paso, permitiendo abortar la evaluación inmediatamente si la intersección se vacía.

6. Análisis Crítico: Debilidades y Desafíos Arquitectónicos

A pesar de sus ventajas algorítmicas, se identificaron cuatro limitaciones operativas fundamentales:

- 1. Latencia Plana y Dificultad de Autoscaling en la Nube:**
Dado que el costo depende exclusivamente de la altura del árbol $h = O(\log D_m)$ y no del volumen de datos en el rango, una consulta estadística toma esencialmente el mismo tiempo (~25 a 30 ns) ya sea para 10 o 30,000 informes. En infraestructura cloud (Kubernetes HPA o AWS Auto Scaling), los modelos elásticos dimensionan recursos según el consumo de CPU o la longitud de colas proporcionales al tamaño del lote. La insensibilidad temporal del AVL hace que el escalado proporcional sea ineficaz; el cuello de botella del servidor se traslada a la **contención de concurrencia y cerrojos en memoria** cuando múltiples hilos acceden a los árboles.
- 2. Sobrecarga de Memoria Principal (RAM):**
Mantener cuatro índices residentes en memoria implica almacenar $O(M \cdot N)$ referencias y punteros de nodos. Para cientos de miles de informes, la huella en RAM puede limitar entornos con recursos acotados, requiriendo esquemas de paginación.
- 3. Costo de Rebalanceo en Ingesta Continua:**
Cada informe nuevo exige actualizar los cuatro AVL. Las rotaciones y el recálculo ascendente de (C, S, SS) (~0.25 μ s/informe) imponen un límite superior a la tasa de ingesta en comparación con motores LSM *append-only* puros.
- 4. Dependencia de la Discretización de Métricas:**
Al redondear notas a 2 decimales, $D_m \leq 401$ ($h \leq 11$). Si se utilizara punto flotante puro de 64 bits sin discretizar, $D_m \approx N$, aumentando la cantidad de nodos y la fragmentación en el heap.

7. Comparación con el Sistema RAP Actual (Ochoa et al., 2018)

El siguiente cuadro contrasta las capacidades operativas del sistema RAP original frente a la arquitectura aumentada desarrollada:

Dimensión de Análisis	Sistema RAP Actual (Ochoa et al., 2018)	Propuesta con Estructura Aumentada + LSM
Almacenamiento	Pasivo / Aislado: Informes en archivos planos o tablas relacionales sin índices multidimensionales.	Desacoplado y Activo: Índices secundarios en RAM sincronizados con LevelDB LSM persistente.
Estadísticas de Cohorte	Fuerza Bruta $O(N)$: Escanea toda la colección para calcular media y varianza.	Aumentación $\Theta(\log D_m)$: Cálculo en 25 nanosegundos mediante resta de prefijos sin tocar datos.
Selección Top-K	Ordenamiento $O(N \log N)$: Costoso al acumular múltiples semestres.	Poda en AVL $O(\log D_m + k)$: 0.13 μ s (440x más rápido que Fuerza Bruta).
Consultas Multi-Criterio	Barrido secuencial multi-filtro con degradación lineal.	Intersección por cardinalidad creciente con salida temprana.
Escalabilidad	Diagnóstico individual local por aula académica.	Escala de Campus: Diseñado para analítica en tiempo real sobre decenas de miles de reportes.
Eficiencia de E/S	Sin filtros probabilísticos: lecturas redundantes para descartar reportes no coincidentes.	Filtros Ribbon y Bloom en LevelDB: 18% menos latencia en hits y descarte casi instantáneo en misses.

8. Conclusiones

1. Validación Empírica: Las mediciones confirman con precisión de nanosegundos las cotas deducidas formalmente: la aumentación transforma cálculos estadísticos costosos en operaciones de complejidad estrictamente logarítmica (speedup de **9,300x**).

2. Transformación Operativa de RAP: El desacoplamiento convierte a RAP en una plataforma analítica institucional capaz de generar tableros de desempeño en tiempo real sin latencias perceptibles.

3. Balance de Diseño: El principal compromiso radica en el consumo de memoria RAM y la necesidad de gestionar la contención de concurrencia en servidores ante una latencia plana e insensible a la entrada.

Referencias Bibliográficas

[1] X. Ochoa et al., "The RAP system: Automatic feedback of oral presentation skills using multimodal analysis and low-cost sensors," in *Proc. LAK '18*. ACM, 2018.

[2] T. H. Cormen, C. E. Leiserson, R. L. Rivest, and C. Stein, *Introduction to Algorithms*, 4th ed. MIT Press, 2022.

[3] G. M. Adelson-Velsky and E. M. Landis, "An algorithm for the organization of information," *Soviet Math. Doklady*, 1962.

[4] P. C. Dillinger and S. Walzer, "Ribbon filter: Practically smaller than bloom and xor," *CoRR*, vol. abs/2103.02515, 2021.

[5] P. E. O'Neil, E. Cheng, D. Gawlick, and E. J. O'Neil, "The log-structured merge-tree (LSM-tree)," *Acta Informatica*, 1996.